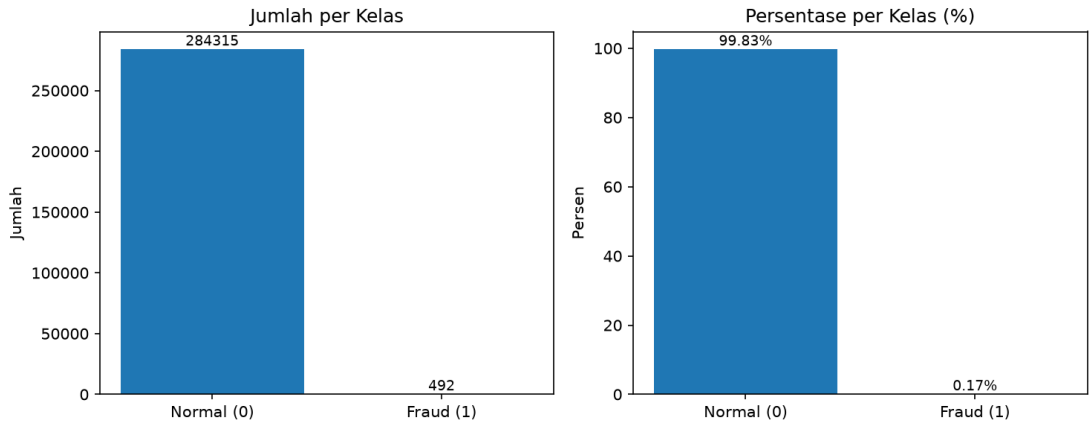
Laporan Tugas Praktikum 3: Classification dengan Ensemble Method dan Class Imbalance

Dataset: Credit Card Fraud Detection (Kaggle)
Nama: Suhail Ainur Rofiq | NRP: 5054251046
Model: Random Forest (Baseline vs SMOTE)

1. Hasil Distribusi Kelas Awal

Atribut target adalah Class dengan dua nilai: 0 untuk transaksi normal dan 1 untuk transaksi penipuan (fraud). Identifikasi dilakukan dengan menghitung jumlah dan persentase tiap kelas menggunakan value_counts serta visualisasi diagram batang jumlah dan persentase. Dataset terdiri dari 284.807 transaksi dengan 30 fitur numerik (Time, V1–V28, Amount) dan 1 label (Class). Tidak ditemukan missing value pada pemeriksaan info. Hasil menunjukkan ketidakseimbangan yang sangat ekstrem, sehingga tahap ini menjadi dasar pemilihan strategi evaluasi.

Kelas	Jumlah	Persentase
0 (Normal)	284.315	99,83%
1 (Fraud)	492	0,17%
Total	284.807	100%



Gambar 1. Distribusi kelas dalam jumlah dan persentase. Batang kelas fraud hampir tidak terlihat pada skala jumlah karena hanya 492 dari 284.807 data, sedangkan pada skala persentase terlihat jelas dominasi kelas normal 99,83%.

Implikasinya, model yang selalu memprediksi kelas normal akan langsung memperoleh accuracy 99,83% tanpa mampu mendeteksi satu pun fraud. Oleh karena itu accuracy tidak dapat dijadikan metrik utama dan evaluasi harus difokuskan pada kelas minoritas. Temuan ini juga menjadi alasan pembagian data latih dan uji menggunakan stratify agar proporsi 0,17% tetap terjaga di kedua bagian.

2. Pendekatan Penanganan Class Imbalance

Dataset dibagi menjadi data latih dan data uji dengan perbandingan 80:20 menggunakan train_test_split dengan stratify=y dan random_state=42. Hasil pembagian adalah data latih 227.451 normal berbanding 394 fraud, dan data uji 56.864 normal berbanding 98 fraud. Stratifikasi memastikan distribusi asli tetap terwakili di data uji sebagai simulasi kondisi dunia nyata.

Bagian	**Normal (0)**	**Fraud (1)**	**Keterangan**
Latih (80%)	227.451	394	Sebelum resampling
Latih SMOTE	227.451	45.490	Sesudah SMOTE 0,2
Uji (20%)	56.864	98	Tetap asli, tanpa resampling

Penanganan imbalance menggunakan oversampling SMOTE (Synthetic Minority Oversampling Technique) dari library imbalanced-learn dengan sampling_strategy=0,2 dan random_state=42. SMOTE membuat sampel fraud sintetis melalui interpolasi tetangga terdekat, bukan duplikasi, sehingga menambah keragaman kelas minoritas. Dipilih rasio 0,2 (fraud menjadi 20% dari normal, yaitu 45.490) agar tidak terlalu agresif seperti rasio 1,0 yang memaksa 394 fraud menjadi 227.451 data sintetis dan terbukti menimbulkan noise. Prinsip penting yang dipatuhi adalah resampling hanya dilakukan pada data latih dengan fit_resample(X_train, y_train), sedangkan data uji tidak disentuh agar tidak terjadi kebocoran data (data leakage) dan evaluasi tetap jujur.

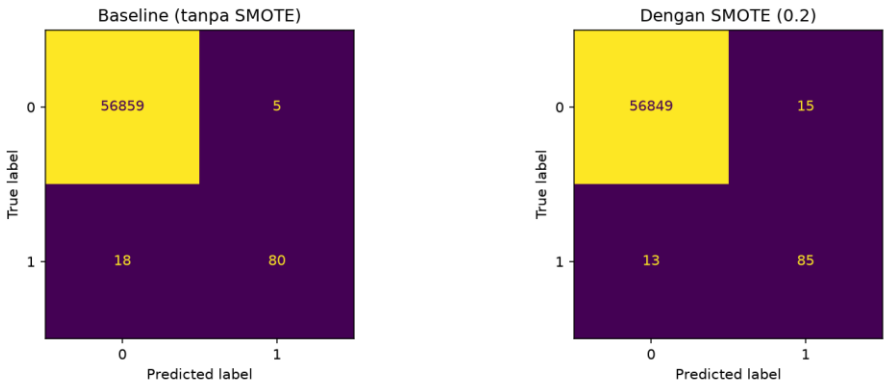
- SMOTE hanya di-fit pada data latih; data uji tetap berdistribusi asli 99,83% vs 0,17%.
- Rasio 0,2 dipilih sebagai kompromi antara menambah sinyal fraud dan menjaga precision.
- Alternatif seperti RandomUnderSampler atau class_weight dipertimbangkan, tetapi SMOTE 0,2 memberikan keseimbangan recall dan AUC terbaik pada percobaan ini.

3. Performansi Model dan Analisis Perbandingan

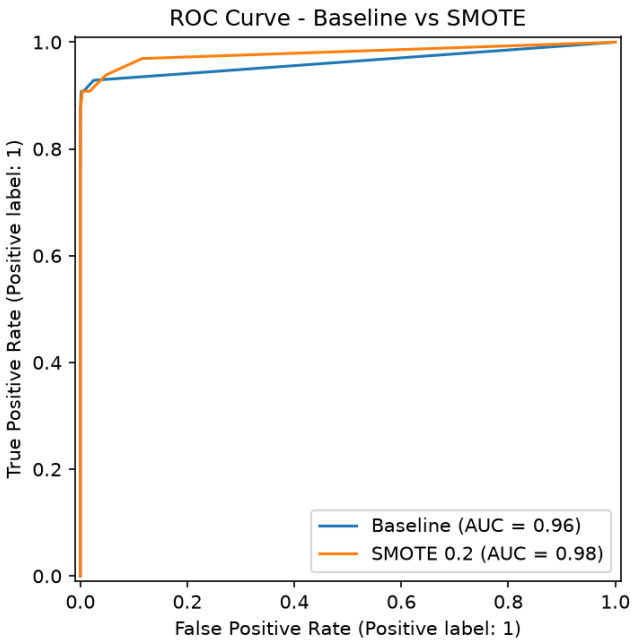
Model yang digunakan adalah ensemble Random Forest dengan n_estimators=100, random_state=42, dan n_jobs=-1. Random Forest dipilih karena berbasis bagging sehingga relatif kebal terhadap imbalance, lebih cepat daripada Gradient Boosting pada 227 ribu baris (454 ribu setelah SMOTE), dan memenuhi ketentuan ensemble method. Dua model dilatih pada

data latih yang berbeda tetapi diuji pada X_test yang sama agar perbandingan adil: (1) Baseline tanpa penanganan imbalance yang dilatih pada X_train asli, dan (2) SMOTE yang dilatih pada X_train_res hasil resampling. Prediksi berupa label (predict) dan probabilitas fraud (predict_proba) untuk perhitungan AUC-ROC.

Metrik (kelas 1)	**Baseline**	**SMOTE 0,2**	**Selisih**
Precision	0,9412	0,8500	-0,0912
Recall	0,8163	0,8673	+0,0510
F1-score	0,8743	0,8586	-0,0157
AUC-ROC	0,9630	0,9793	+0,0163
Accuracy	0,9996	0,9995	~sama



Gambar 2. Confusion matrix kedua model pada data uji yang sama. SMOTE mengurangi false negative (fraud yang lolos sebagai normal) tetapi menambah false positive (normal yang dikira fraud). Pola ini menjelaskan mengapa recall naik sedangkan precision turun.



Gambar 3. Kurva ROC Baseline vs SMOTE. Kurva SMOTE berada sedikit di atas baseline dengan AUC 0,9793 berbanding 0,9630, menunjukkan kemampuan ranking probabilitas fraud yang lebih baik pada berbagai threshold.

Analisis perbandingan menunjukkan trade-off yang wajar. Baseline unggul pada precision (0,94) dan F1 (0,87) karena jarang memberi alarm palsu, tetapi recall hanya 0,81 sehingga sekitar 18 dari 98 fraud di data uji lolos tidak terdeteksi. SMOTE menaikkan recall menjadi 0,87 dan AUC menjadi 0,98 sehingga lebih banyak fraud tertangkap, dengan biaya precision turun ke 0,85 karena lebih banyak false alarm. Pada konteks deteksi penipuan, recall dan AUC lebih penting daripada precision semata karena biaya fraud yang lolos jauh lebih besar daripada biaya verifikasi tambahan. Accuracy kedua model sama-sama sekitar 99,95% sehingga tidak informatif: model malas yang selalu memprediksi normal pun mendapat 99,83% tanpa mendeteksi fraud sama sekali. Oleh karena itu kesimpulan evaluasi harus berbasis recall, F1, dan AUC kelas minoritas, bukan accuracy.

Percobaan tambahan dengan SMOTE 1,0 (tanpa pembatasan rasio) menghasilkan precision 0,8351, recall 0,8265, dan F1 0,8308, yaitu lebih buruk pada ketiga metrik dibanding SMOTE 0,2. Hal ini memperkuat argumen bahwa oversampling 1:1 terlalu ekstrem untuk imbalance 0,17% karena 394 sampel asli dipaksa menjadi 227.451 data sintetis yang noisy dan menyebabkan overgeneralisasi. Rasio 0,2 terbukti lebih seimbang dan menjadi rekomendasi pendekatan pada laporan ini.

4. Kesimpulan

- Distribusi awal sangat imbalance: 284.315 normal (99,83%) vs 492 fraud (0,17%).
- Split 80:20 dengan stratify menjaga proporsi; SMOTE 0,2 hanya diterapkan pada data latih (227.451 vs 45.490) sedangkan data uji tetap asli (56.864 vs 98).
- Random Forest Baseline unggul precision/F1, sedangkan SMOTE unggul recall/AUC (0,8673 dan 0,9793). Untuk deteksi fraud, SMOTE 0,2 lebih disarankan karena menangkap lebih banyak penipuan.
- Accuracy tidak cukup karena didominasi kelas mayoritas; evaluasi wajib memakai precision, recall, F1-score, AUC-ROC, dan confusion matrix pada kelas minoritas.