

Laporan Praktikum 2: Praproses Data

Nama : Suhail Ainur Rofiq

NRP : 5054251046

Prodi : Rekayasa Kecerdasan Artifisial

1. Tujuan dan Dataset

Praktikum ini menerapkan tahapan praproses agar dataset siap untuk analisis/model yakni, pembersihan (missing, outlier), transformasi (encoding, standarisasi), dan reduksi dimensi (korelasi, PCA). Dataset train.csv berisi 1460 baris dan 81 kolom (Id + 80 atribut + SalePrice sebagai target). Atribut mencakup ukuran (LotArea, GrLivArea), tahun (YearBuilt, YearRemodAdd), kualitas/kondisi (OverallQual, OverallCond), serta atribut basement, garasi, dan penjualan.

2. Import Dataset

Dataset diimpor dengan pandas read_csv. Struktur dicek dengan .head(), .shape, dan .info(), dilengkapi .describe(). Hasil: shape (1460, 81), 38 kolom numerik (int64/float64) dan 43 kolom kategorikal (object/string), tidak ada kolom yang seluruhnya kosong. Lima baris pertama menunjukkan karakteristik umum yakni, MSZoning dominan RL, Street Pave, serta banyak NaN pada Alley, PoolQC, Fence, dan MiscFeature.

3. Pembersihan Data

3.1 Nilai hilang

Jumlah missing value per atribut:

Kolom	Jumlah NaN	Persen
PoolQC	1453	99.52%
MiscFeature	1406	96.30%
Alley	1369	93.77%
Fence	1179	80.75%
MasVnrType	872	59.73%
FireplaceQu	690	47.26%
LotFrontage	259	17.74%
GarageType/YrBltn/Finish/Qual/Cond	81	5.55%
BsmtQual/Cond/FinType1 (≈)	37	2.53%
BsmtExposure/FinType2	38	2.60%
MasVnrArea	8	0.55%
Electrical	1	0.07%

3.2 Hapus kolom


Lima kolom dengan missing >50% dihapus: PoolQC, MiscFeature, Alley, Fence, MasVnrType. Kolom Id ikut dihapus karena identifier, bukan fitur prediktif. Shape menjadi (1460, 75). FireplaceQu (47.26%) dipertahankan karena NaN bermakna domain, tidak ada fireplace, sehingga informatif bila diisi 'None'.

3.3 Imputasi

Tiga fitur numerik sisa (LotFrontage, MasVnrArea, GarageYrBlt) berdistribusi skewed (histogram condong kanan, median jauh dari mean), sehingga diisi median. LotFrontage 69.0, MasVnrArea 0.0, GarageYrBlt 1980.0. Sepuluh fitur kategorikal basement/garasi/fireplace diisi 'None' karena mempunyai makna tidak ada fasilitas tersebut. Electrical (1 baris) diisi modus SBrkr. Setelah ini total missing value nya Adalah 0. Tidak ada baris yang terduplikat sehingga tidak perlu dihapus.

4. Deteksi dan Penanganan Outlier


Deteksi memakai boxplot untuk seluruh 36 kolom numerik (kecuali Id) dan metode IQR ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$). Contoh temuan yaitu, EnclosedPorch sebanyak 208 (14.25%), BsmtFinSF2 sebanyak 167 (11.44%), OverallCond sebanyak 125 (8.56%), LotFrontage sebanyak 88, LotArea sebanyak 69, SalePrice sebanyak 61 (4.18%). Scatterplot GrLivArea vs SalePrice memperlihatkan 2 titik anomali: GrLivArea > 4000 tetapi SalePrice < 300000.



Gambar 1. Scatterplot GrLivArea vs SalePrice. Dua titik di kanan bawah adalah anomali yang dihapus.

Penanganannya dengan cara 2 baris anomali tersebut dihapus (1460 menjadi 1458) karena tidak masuk akal rumah yang sangat luas harganya sangat murah. Sisa outlier IQR dipertahankan tanpa capping karena masih valid namun langka. Sebagian adalah false-positive dari fitur zero-inflated (mayoritas nilai 0, misal EnclosedPorch 85.7% nol dan ScreenPorch 92% nol sehingga $Q3=0$ dan Upper Bound=0), sebagian dari skala ordinal/diskrit (OverallCond, MSSubClass, GarageCars), dan sebagian rumah mewah yang memang skewed kanan (LotArea, SalePrice). Menghapus

seluruh union outlier akan membuang terlalu banyak baris sehingga akan kehilangan informasi penting.



Gambar 2. Distribusi SalePrice skewed kanan, mayoritas 130-214 ribu.


5. Transformasi Data

Fitur dan target dipisah, X (1458, 74) dan y SalePrice (1458,). Encoding kategorikal memakai One Hot Encoding. `pd.get_dummies(drop_first=True)` untuk menghindari dummy trap. Kolom bertambah 74 menjadi 242. Standarisasi memakai `StandardScaler` hanya pada 36 fitur numerik asli hingga mean mendekati 0 dan std mendekati 1. Kolom dummy dibiarkan 0/1 karena berdistribusi Bernoulli dan tidak tepat untuk di-scale.

6. Reduksi Dimensi

6.1 Korelasi


Korelasi tertinggi terhadap SalePrice yaitu, OverallQual(0.79), GrLivArea(0.71), GarageCars(0.64), GarageArea(0.62), TotalBsmtSF(0.61), 1stFlrSF(0.61). Ditemukan multikolinearitas kuat yaitu, GarageCars-GarageArea (0.88) (jumlah mobil vs luas garasi mengukur hal sama), TotalBsmtSF-1stFlrSF (0.82), TotRmsAbvGrd-GrLivArea (0.83). Dari tiap pasangan dibuang satu, GarageArea, 1stFlrSF, TotRmsAbvGrd, disisakan GarageCars, TotalBsmtSF, GrLivArea yang lebih berkorelasi dengan target. Dimensi menjadi 239 kolom.



Gambar 3. Heatmap korelasi top-10 fitur terhadap SalePrice.

6.2 PCA

Principal Component Analysis dengan $n_components=0.90$ mempertahankan 90% varians. Hasilnya adalah 239 kolom menjadi 45 komponen (90.04% varians terjaga). Data lebih ringan tanpa kehilangan informasi penting.



Gambar 4. Kurva varians kumulatif PCA, garis putus-putus pada 90%.

7. Ringkasan Dataset Akhir

Aspek	Hasil
Awal	1460 baris x 81 kolom
Setelah drop >50% + Id	1460 x 75
Missing Value Akhir	0
Duplikat	0
Setelah hapus 2 anomali	1458 x 75
X / y	X (1458, 74), y (1458,)
Setelah one-hot	(1458, 242)
Setelah drop multikolinearitas	(1458, 239)
Setelah PCA 90%	(1458, 45), 90.04% varians
File akhir	HousePriceClean.csv (1458 x 46 = 45 PC + SalePrice)

Dataset akhir bersih (tanpa missing/duplikat), outlier anomali ditangani, fitur numerik terstandarisasi, kategorikal ter-encoding, dimensi tereduksi dari 239 menjadi 45 dengan 90.04% informasi terjaga, siap untuk modelling. Visualisasi lengkap (boxplot 36 fitur, histogram, heatmap, scatterplot) tersedia di file notebook.