

Laporan Analisis Praktikum Data Mining

Game Dataset di Itch.io

1. Deskripsi Dataset

1.1 Pengenalan Dataset

Dataset ini merupakan kumpulan data metadata game indie yang dikumpulkan secara langsung dari platform distribusi digital [itch.io](https://itch.io/games) (<https://itch.io/games>). [itch.io](https://itch.io/games) adalah salah satu situs web terpopuler di dunia bagi para pengembang game independen *indie developers* untuk memublikasikan, menjual, dan membagikan karya game mereka kepada komunitas global.

Disini tujuan saya mengambil dataset dari berbagai game di [itch.io](https://itch.io/games) adalah untuk mengetahui detail detail game yang dibuat oleh indie developer dan melihat peluang untuk mem publish game di [itch.io](https://itch.io/games)

1.2 Karakteristik Dataset

Berdasarkan hasil analisis awal, dataset game dari platform itch.io memiliki beberapa karakteristik utama. Dataset ini terdiri dari 3.000 baris sampel game dengan 9 fitur utama, serta 3 atribut tambahan yang diperoleh melalui proses parsing dan feature engineering. Dari sisi distribusi harga, karakteristik yang paling menonjol adalah dominasi game gratis, yaitu sekitar 86.03% dari keseluruhan sampel memiliki harga sebesar \$0,00. Kondisi tersebut menyebabkan variabel harga memiliki distribusi yang sangat miring ke kanan (positively skewed).

Selain itu, dataset memiliki tipe data yang heterogen. Data yang digunakan mencakup teks tidak terstruktur (unstructured text) pada atribut deskripsi, data kategorikal nominal seperti genre dan author, data numerik kontinu seperti harga dan diskon, data numerik diskrit seperti jumlah platform, serta data multivalue nominal pada atribut platform. Atribut platform memiliki sifat multivalue karena satu game dapat mendukung lebih dari satu platform dalam satu nilai, misalnya "windows8, tux, apple", yang menunjukkan bahwa game tersebut dapat dijalankan pada Windows, Linux, dan Mac.

Dari sisi kelengkapan data (data completeness), terdapat beberapa atribut yang memiliki nilai kosong (missing values). Atribut diskon memiliki persentase missing values yang cukup tinggi, yaitu sekitar 97,3%, yang menunjukkan bahwa sebagian besar game dalam dataset dijual dengan

harga normal tanpa diskon. Sementara itu, atribut deskripsi_singkat memiliki missing values sekitar 6,0%. Kondisi tersebut perlu diperhatikan pada tahap preprocessing agar tidak memengaruhi hasil analisis data pada tahap selanjutnya.

1.3 Atribut Dataset

Dataset terdiri dari beberapa atribut yang memiliki jenis dan karakteristik berbeda. Penjelasannya sebagai berikut

1. game_id (Nominal / Unique ID)
Identitas unik yang diberikan oleh platform itch.io untuk membedakan setiap game secara spesifik.
2. judul (Nominal / Teks)
Nama resmi dari game yang terdapat pada platform itch.io.
3. author (Nominal / Kategorikal)
Nama pengembang (developer), pembuat, atau studio indie yang menerbitkan game tersebut.
4. deskripsi_singkat (Teks / Unstructured Text)
Berisi deskripsi atau tagline singkat yang memberikan gambaran mengenai isi atau konsep game.
5. harga → harga_numeric (Nominal → Numerik Kontinu / Rasio)
Berisi harga awal game dalam satuan Dolar Amerika (USD). Data awal berupa teks, seperti "Free" atau "\$14.99", kemudian diubah melalui proses parsing menjadi nilai numerik bertipe float, seperti 0.0 dan 14.99.
6. diskon → diskon_numeric (Nominal → Numerik Kontinu / Rasio)
Berisi persentase potongan harga yang berlaku pada game. Data awal berupa teks, seperti "-50%", kemudian diubah melalui proses parsing menjadi nilai numerik, misalnya 50.0.
7. genre (Nominal / Kategorikal)
Menunjukkan kategori atau genre utama dari game, seperti Visual Novel, Adventure, Simulation, Action, Role Playing, dan Puzzle.
8. platform (Multivalued Nominal)
Berisi daftar platform atau sistem operasi yang didukung oleh game. Satu game dapat memiliki lebih dari satu platform, misalnya windows8, tux (Linux), apple (Mac), dan android.
9. jumlah_platform (Numerik Diskrit / Count)
Menunjukkan jumlah platform yang didukung oleh setiap game. Atribut ini merupakan hasil perhitungan dari atribut platform, dengan nilai berkisar antara 1 hingga 5.
10. is_free (Nominal / Binary Boolean)
Merupakan atribut hasil feature engineering yang menunjukkan apakah sebuah game bersifat gratis atau berbayar. Nilai True menunjukkan game gratis dengan harga 0.0, sedangkan False menunjukkan game berbayar.

2. Statistik Deskriptif

Statistik deskriptif digunakan untuk melihat gambaran umum dari atribut numerik yang terdapat pada dataset. Beberapa ukuran yang digunakan dalam analisis ini adalah rata-rata (mean), median, modus, standar deviasi, nilai minimum, dan nilai maksimum. Hasil perhitungannya dapat dilihat pada tabel berikut.

2.1 Atribut Numerik

Perhitungan statistik deskriptif dilakukan pada atribut numerik yang telah di-parse:

Atribut Numerik	Rata-rata (Mean)	Median (Q2)	Modus	Std. Deviasi	Minimum	Maksimum
harga_numeric (\$)	\$1.34	\$0.00	\$0.00	\$4.19	\$0.00	\$30.00
diskon_numeric (%)	1.52%	0.00%	0.00%	11.15%	0.00%	100.00%
jumlah_platform	2.12 OS	2.00 OS	1.00 OS	1.09 OS	1 OS	5 OS

Variabel harga memiliki distribusi yang positively skewed atau miring ke kanan. Hal ini dapat dilihat dari nilai mean sebesar \$1.34 yang lebih besar dibandingkan median dan modus yang sama-sama bernilai \$0.00. Kondisi tersebut terjadi karena mayoritas game (86.03%) memiliki harga \$0.00 atau gratis, sedangkan sebagian kecil game premium memiliki harga yang lebih tinggi, yaitu sekitar \$15 hingga \$30.

2.2 Atribut Kategorikal

1. Genre Dominan

Genre Visual Novel menjadi genre yang paling banyak ditemukan dalam dataset, yaitu sebanyak 918 game atau 30,6% dari keseluruhan data. Setelah itu, genre Adventure menempati posisi kedua dengan 391 game (13,0%), diikuti oleh Simulation sebanyak 243 game (8,1%), Uncategorized sebanyak 205 game (6,8%), dan Action sebanyak 195 game (6,5%).

2. Platform OS Dominan

Untuk platform yang digunakan, kombinasi Windows, Linux, dan Mac dengan nilai windows8, tux, apple menjadi konfigurasi platform yang paling banyak ditemukan, yaitu

sebanyak 792 game. Selanjutnya, game yang hanya mendukung Windows (windows8) berjumlah 744 game, diikuti oleh game yang dapat dimainkan melalui Web sebanyak 490 game. Sementara itu, kombinasi Windows, Linux, Mac, dan Android (windows8, tux, apple, android) ditemukan pada 364 game.

3. Proporsi Status Game

Berdasarkan status harganya, sebagian besar game dalam dataset merupakan game gratis. Sebanyak 2.581 game, yang menunjukkan bahwa game tersebut dapat dimainkan secara gratis. Sementara itu, sebanyak 419 game atau 13,97% yang menunjukkan bahwa game tersebut merupakan game berbayar.

3. Penanganan Data

3.1 Penanganan Nilai Hilang dan Duplikat

Pada tahap penanganan nilai hilang, atribut diskon memiliki 2.917 nilai NaN atau sekitar 97,23%. Nilai kosong tersebut tidak menunjukkan data yang rusak, tetapi menunjukkan bahwa game dijual dengan harga normal tanpa diskon. Oleh karena itu, nilai NaN diubah menjadi 0,0% pada atribut diskon_numeric. Sementara itu, atribut deskripsi_singkat memiliki 177 nilai NaN atau sekitar 5,90%, yang kemudian diisi dengan nilai "Tanpa Deskripsi". Dari hasil pengecekan data duplikat, tidak ditemukan data yang sama, sehingga seluruh data dalam dataset bersifat unik.

3.2 Data Parsing dan Transformasi

Pada tahap preprocessing, data harga dan diskon diubah dari bentuk teks menjadi data numerik menggunakan ekspresi reguler. Proses ini digunakan untuk mengambil angka dari data seperti "\$14.99" menjadi 14.99, "Free" menjadi 0.0, dan "-50%" menjadi 50.0. Selain itu, dibuat fitur baru bernama is_free untuk membedakan game gratis dan berbayar. Nilai True diberikan jika harga game adalah 0.0, sedangkan nilai False diberikan untuk game yang berbayar.

3.3 Deteksi Outlier

Deteksi outlier dilakukan menggunakan metode IQR (Interquartile Range), dengan rumus $IQR = Q3 - Q1$ dan batas atas sebesar $Q3 + 1,5 \times IQR$. Pada atribut harga_numeric, nilai Q1 dan Q3 sama-sama sebesar \$0,00 sehingga nilai IQR juga sebesar 0,00. Dari hasil deteksi ditemukan 419 outlier atau 13,97%, yang merupakan seluruh game berbayar dengan harga lebih dari \$0,00. Kondisi ini terjadi karena sebagian besar game dalam dataset merupakan game gratis, sehingga game berbayar dianggap sebagai outlier secara matematis.

Pada atribut diskon_numeric, ditemukan 68 outlier atau sebesar 2,27%. Data tersebut merupakan game yang sedang mendapatkan diskon, sehingga nilainya cukup berbeda dibandingkan sebagian

besar data lainnya yang tidak memiliki diskon. Sementara itu, pada atribut jumlah_platform tidak ditemukan outlier. Seluruh data berada dalam rentang yang dianggap normal, yaitu antara 1 hingga 5 platform.

4. Visualisasi Data

4.1 Analisis Univariat

Histogram harga game berbayar menunjukkan bahwa distribusi harga cenderung miring ke kanan. Sebagian besar game berbayar berada pada rentang harga yang relatif murah, yaitu sekitar \$0,99 hingga \$4,99. Sementara itu, bar chart genre menunjukkan bahwa Visual Novel menjadi genre yang paling dominan dengan 918 game, diikuti oleh Adventure dengan 391 game. Hal ini menunjukkan bahwa kedua genre tersebut cukup banyak ditemukan dalam dataset game indie di itch.io.

4.2 Analisis Bivariat

Scatter plot antara harga dan diskon menunjukkan bahwa diskon besar, bahkan hingga 100%, lebih sering diberikan pada game dengan harga awal di bawah \$5. Boxplot harga berdasarkan genre menunjukkan bahwa Role Playing dan Simulation memiliki variasi harga berbayar yang lebih tinggi dibandingkan Visual Novel dan Adventure.

Berdasarkan correlation heatmap, harga_numeric dan harga_setelah_diskon memiliki korelasi positif yang sangat kuat dengan nilai $r = 0,998$. Sementara itu, jumlah_platform dan harga_numeric memiliki korelasi positif yang lemah dengan nilai $r = 0,082$, sehingga jumlah platform hanya memiliki hubungan yang kecil dengan harga game. Panjang_judul dan diskon_numeric memiliki korelasi yang sangat kecil, yaitu sekitar $r = 0,01$, sehingga keduanya hampir tidak memiliki hubungan linear.